Prédiction du Churn Client

Un projet de Machine Learning supervisé de bout en bout

André Kevin LOUKANOU LOUZOLO

Master Mathématiques Appliquées — Statistiques et Data Science
Université d'Aix-Marseille

Projet réalisé sur le jeu de données public IBM Telco Customer Churn (7 043 clients), pour démontrer le cycle complet d'un projet de classification supervisée.

July 24, 2026

Contents

1 Contexte et cadrage du problème **2**
1.1 Jeu de données . . . 2
1.2 Pourquoi l'accuracy seule ne suffit pas . . . 2

2 Données et qualité **2**
2.1 Un défaut de qualité de données réel . . . 2

3 Analyse exploratoire (EDA) **2**
3.1 Principaux signaux identifiés . . . 2

4 Préparation des données **3**

5 Modélisation et comparaison **4**

6 Évaluation détaillée **4**
6.1 Sur le choix du seuil de décision . . . 4

7 Interprétation du modèle **4**
7.1 Facteurs qui augmentent le risque de départ . . . 5
7.2 Facteurs qui protègent contre le départ . . . 5
7.3 Un point de rigueur méthodologique . . . 5

8 Recommandation business **6**
8.1 Limites . . . 6

1 Contexte et cadrage du problème

Le **churn** (attrition) désigne la perte de clients par une entreprise. L'objectif est de construire un modèle de *machine learning* supervisé capable d'identifier, en amont, les clients les plus susceptibles de résilier — afin de permettre une action de rétention ciblée avant le départ effectif.

1.1 Jeu de données

Ce projet utilise le jeu de données public **IBM Telco Customer Churn** (7 043 clients, 21 variables), un des jeux de données de référence en Data Science pour ce type de problème.

1.2 Pourquoi l'accuracy seule ne suffit pas

Le churn est déséquilibré par nature : **26,5 %** des clients de ce jeu de données sont partis, contre 73,5 % restés. Un modèle prédisant systématiquement le client reste obtiendrait déjà 73,5 % d'accuracy sans détecter le moindre départ. Le choix des métriques (precision, recall, F1) est donc traité comme un enjeu central, et la priorité métier retenue est de **maximiser le recall** : le coût d'un client perdu est jugé supérieur au coût d'une relance inutile.

2 Données et qualité

Le jeu de données comprend des variables démographiques (genre, âge, situation familiale), contractuelles (type de contrat, mode de paiement), d'usage (ancienneté, services souscrits) et financières (charges mensuelles et totales).

2.1 Un défaut de qualité de données réel

La colonne `TotalCharges`, censée être numérique, est stockée en texte et contient **11 valeurs « vides déguisées»** (une chaîne composée uniquement d'un espace) plutôt que de vraies valeurs manquantes (`NaN`) — ces 11 clients ont tous une ancienneté (`tenure`) de 0 mois : ils n'ont simplement pas encore reçu de première facture totale. Ce défaut est invisible à un simple `isnull()` et nécessite une vérification plus fine (type de colonne, recherche de chaînes vides) pour être détecté.

Ces 11 lignes (0,16 % du jeu de données) ont été retirées après conversion explicite en type numérique.

3 Analyse exploratoire (EDA)

3.1 Principaux signaux identifiés

- **Type de contrat** : **42,7 %** de churn en contrat mensuel, contre seulement **2,8 %** en engagement deux ans — un facteur de risque 15 fois plus élevé.
- **Mode de paiement** : le chèque électronique est associé à **45,3 %** de churn, contre 15 à 19 % pour les autres modes — les modes de paiement automatisés apparaissent nettement protecteurs.
- **Service internet** : la fibre optique atteint **41,9 %** de churn, contre 19 % en ADSL — un signal contre-intuitif (meilleur service, plus de départs), généralement attribué à un effet prix/concurrence.
- **Ancienneté (`tenure`)** : corrélation négative la plus forte parmi les variables numériques ($r = -0{,}354$).

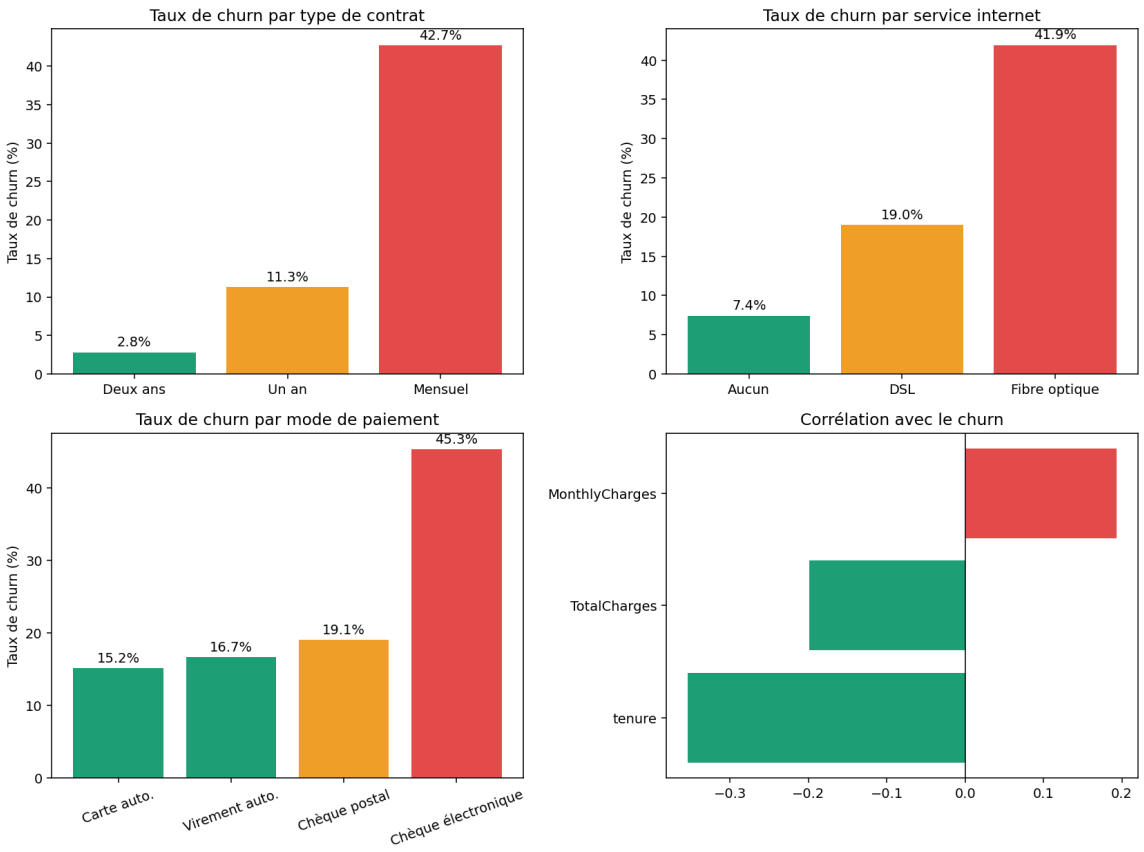


Figure 1: Taux de churn par type de contrat, service internet, mode de paiement, et corrélations des variables numériques avec le churn.

- **Redondance détectée** : `tenure` et `TotalCharges` sont fortement corrélées ($r = 0{,}826$), un point traité lors de la préparation des données.

4 Préparation des données

1. Suppression de l'identifiant client et conversion de la variable cible en binaire.
2. Création d'une variable dérivée `charge_moyenne_reelle` = `TotalCharges` / `tenure`, pour limiter la redondance entre les deux variables sans en supprimer aucune.
3. Encodage binaire simple pour les variables à 2 modalités (Oui/Non, genre), et one-hot encoding (`drop_first=True`) pour les variables à 3 modalités ou plus (type de contrat, service internet, options souscrites, mode de paiement).
4. Standardisation des variables numériques.
5. Séparation entraînement/test (80/20), stratifiée pour préserver le taux de churn (26,6 %) dans les deux ensembles.

Point de vigilance identifié : plusieurs variables d'options (sécurité en ligne, support technique, streaming...) partagent une modalité No internet service , strictement redondante avec `InternetService = No`. Un client sans internet ne peut logiquement pas avoir ces services — ces colonnes encodées portent donc en partie la même information.

5 Modélisation et comparaison

Trois modèles ont été comparés par validation croisée à 5 plis :

Modèle	Recall moyen (5-fold)	Stabilité
Régression logistique	**0,805**	±0,022
Random Forest	0,477	±0,018
Gradient Boosting	0,523	±0,023

La régression logistique domine nettement, un résultat cohérent avec un projet préliminaire mené sur un jeu de données simulé — la conclusion se vérifie donc sur deux jeux de données distincts, ce qui renforce sa robustesse.

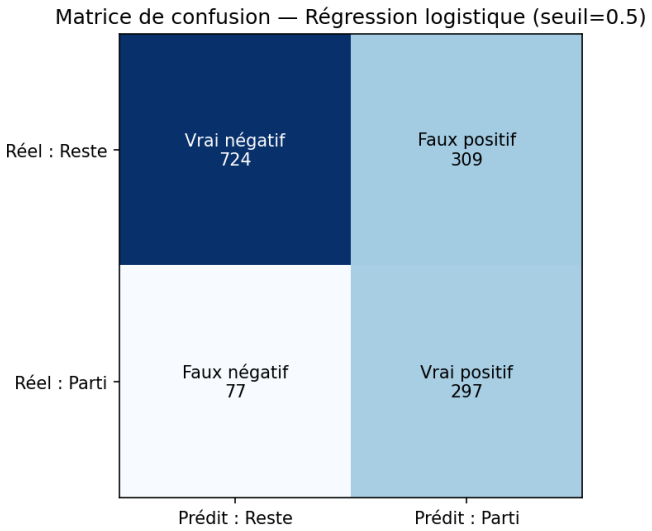


Figure 2: Matrice de confusion du modèle retenu (régression logistique, seuil = 0,5) sur le jeu de test (1 407 clients).

6 Évaluation détaillée

Classe	Precision	Recall	F1-score
Reste (0)	0,90	0,70	0,79
Parti (1)	**0,49**	**0,79**	**0,61**
Accuracy globale		0,73	

Lecture métier : sur 374 clients réellement partis dans le jeu de test, le modèle en détecte **297 (79 %)**, au prix de 309 fausses alertes sur 1 033 clients réellement restés.

6.1 Sur le choix du seuil de décision

Une analyse de la courbe precision/recall a identifié un seuil de 0,61 comme optimal au sens du F1-score (F1 = 0,627, contre ∼0,60 au seuil par défaut). Ce seuil a été **délibérément écarté** : il ferait chuter le recall de 0,79 à environ 0,60, contraire à la priorité métier définie au cadrage (maximiser la détection des départs). Le seuil par défaut (0,5) est conservé.

7 Interprétation du modèle

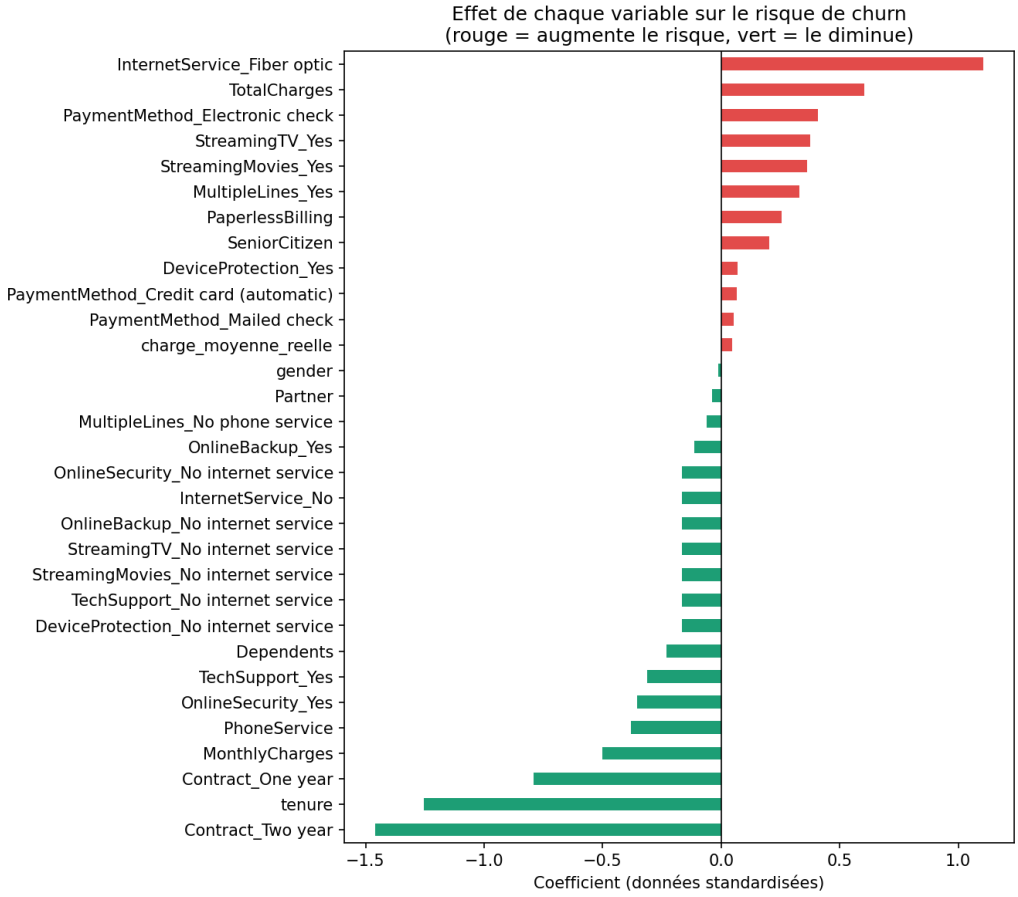


Figure 3: Coefficients de la régression logistique (données standardisées).

7.1 Facteurs qui augmentent le risque de départ

1. **Service internet fibre optique** — le facteur de risque le plus fort de tout le modèle
2. **Paiement par chèque électronique**
3. **Options de streaming souscrites (TV, films)**

7.2 Facteurs qui protègent contre le départ

1. **Contrat de deux ans** — le facteur protecteur le plus fort
2. **Ancienneté (`tenure`)**
3. **Contrat d'un an**
4. **Support technique et sécurité en ligne souscrits**

7.3 Un point de rigueur méthodologique

Le coefficient de `TotalCharges` est positif (+0,604) dans le modèle final malgré une corrélation brute négative en exploration ($r = -0{,}199$). Ce changement de signe s'explique par la forte redondance avec `tenure` : une fois l'effet de l'ancienneté isolé, le signal résiduel de `TotalCharges` et `MonthlyCharges` devient difficile à interpréter isolément. **Ces trois variables corrélées doivent être lues comme un ensemble, non individuellement.**

8 Recommandation business

Profil du client à risque prioritaire : client en contrat mensuel, équipé de la fibre optique, payant par chèque électronique, avec une faible ancienneté et sans options de protection souscrites (sécurité en ligne, support technique).

Actions recommandées, par ordre de priorité :

1. **Inciter au passage vers un contrat engagé** (remise, mois offerts) dès les premiers mois, en priorité pour les clients fibre.
2. **Investiguer la satisfaction des clients fibre** : le prix plus élevé et/ou la qualité perçue du service semblent être des facteurs de churn directs.
3. **Encourager le passage à un prélèvement automatique** pour les clients payant par chèque électronique, un mode de paiement fortement associé au désengagement.

Le modèle détecte 79 % des départs réels, un compromis jugé raisonnable pour déclencher des actions de rétention à faible coût plutôt qu'une décision coûteuse et irréversible.

8.1 Limites

- Les coefficients de `tenure`, `MonthlyCharges` et `TotalCharges` doivent être interprétés conjointement, en raison de leur forte corrélation mutuelle.
- Le seuil de décision (0,5) reflète une priorité métier assumée (maximiser le recall) ; un contexte d'entreprise différent, avec un coût de fausse alerte plus élevé, justifierait un seuil plus restrictif.

Stack technique : Python, Pandas, Scikit-learn, Matplotlib
Jeu de données : IBM Telco Customer Churn (domaine public)